UNIVERSIDAD CATÓLICA DEL MAULE
Facultad de Ciencias de la Ingeniería | Escuela de Ingeniería Civil Informática
Actividad Curricular: INF-522 — Gestión II (Sistemas de Información y Data Warehousing)

INFORME TÉCNICO DE EVALUACIÓN 2 (35%)

Estrategia de Datos y Arquitectura ETL en Airflow y PostgreSQL para el Sector Astronómico en Chile

Diseño e Implementación de un Pipeline de Datos Abiertos: Observatorio Europeo Austral (ESO) y Broker ALeRCE (CMM / MAS)

Académicos:	Natalia Morales | Sebastián Farías
Carrera:	Ingeniería Civil Informática
Fecha de Entrega:	Noviembre 2026
Repositorio GitHub:	https://github.com/Francoisere/Gestion2-ESO
Ponderación:	Evaluación 2 — 35% de la Nota Final
Componentes Entregados:	Informe PDF, Presentación PPTX (11 láminas), DAGs Airflow, Scripts Python, DDL PostgreSQL, Suite de Pruebas CLI, Contenedores Docker.

Resumen Ejecutivo: *El presente informe documenta el desarrollo de un sistema analítico de datos de extremo a extremo que extrae, transforma y consolida metadatos astronómicos generados en territorio chileno por el Observatorio Europeo Austral (ESO) y eventos transitorios clasificados en tiempo real por el broker nacional ALeRCE (Centro de Modelamiento Matemático / Instituto Milenio de Astrofísica). La solución está orquestada mediante 3 DAGs desacoplados en Apache Airflow, un modelo dimensional en estrella en PostgreSQL organizado en 4 capas (raw, staging, dw, mart), auditoría automatizada y 5 indicadores de gestión operacional y de seguimiento.*

1. Introducción y Contexto del Sector Astronómico en Chile

Chile ostenta una posición geográfica y atmosférica privilegiada a nivel mundial: sus cielos en las regiones de Antofagasta, Atacama y Coquimbo presentan más de 300 noches despejadas al año, humedad relativa extremadamente baja y una turbulencia atmosférica mínima. Esta condición ha consolidado al país como la **capital astronómica del planeta**, concentrando más del 50% de la capacidad de observación óptica e infrarroja mundial a través de los complejos científicos más avanzados de la humanidad, tales como Cerro Paranal (Very Large Telescope - VLT), el Observatorio La Silla, y la meseta de Chajnantor con APEX y el radiotelescopio ALMA.

No obstante, la astronomía moderna ha entrado en la era del *Big Data*. El cielo nocturno ya no es un escenario estático, sino un flujo continuo de millones de eventos transitorios: explosiones de supernovas, estrellas variables pulsantes, núcleos galácticos activos y microlentes gravitacionales. Para enfrentar esta avalancha de datos, la comunidad científica chilena, a través de la Universidad de Chile (CMM), el Instituto Milenio de Astrofísica (MAS), la Universidad de Concepción y la Fundación Data Observatory, desarrolló **ALeRCE (Automatic Learning for the Rapid Classification of Events)**, un broker astronómico que ingiere millones de alertas nocturnas y las clasifica automáticamente mediante algoritmos de Machine Learning.

En este contexto, surge un problema crítico de gestión operativa y científica: **¿cómo coordinar de manera eficiente la ingesta masiva de alertas astronómicas con el valioso y costoso tiempo de exposición de los telescopios de clase mundial instalados en Chile?** El presente proyecto aborda dicha problemática mediante una solución integral de Inteligencia de Negocios, Data Warehousing y automatización ETL en Apache Airflow, articulando datos de telescopios de ESO con alertas clasificadas de ALeRCE bajo una arquitectura en 4 capas.

2. Selección, Justificación y Viabilidad de las APIs Públicas

Para dar cabal cumplimiento a los requisitos de la rúbrica (APIs públicas de datos abiertos de Chile, obtenidas 100% mediante código sin descargas manuales, sin repetir las fuentes genéricas y con un campo de cruce claro), se seleccionaron dos infraestructuras tecnológicas científicas operativas en el país:

2.1. API 1: ESO Science Archive — Servicio TAP (Table Access Protocol)

Justificación Territorial en Chile: Aunque el Observatorio Europeo Austral (ESO) es una organización intergubernamental europea, el **100% de sus telescopios, instrumentos científicos y operaciones nocturnas residen en territorio chileno**. Sus observatorios operan en Cerro Paranal (Región de Antofagasta, VLT/VLTI), La Silla (Región de Coquimbo, telescopios de 3.6m y NTT), y en la planicie de Chajnantor (radiotelescopio ALMA y APEX), bajo acuerdos de cooperación de largo plazo suscritos con el Estado de Chile.

Funcionamiento Técnico: ESO implementa el estándar internacional IVOA TAP (International Virtual Observatory Alliance - Table Access Protocol). Expone un endpoint HTTP síncrono en https://archive.eso.org/tap_obs/sync que acepta consultas en lenguaje **ADQL** (Astronomical Data Query Language, derivado de SQL-92). La API responde peticiones GET o POST con el parámetro FORMAT=json, entregando metadatos completos y filas estructuradas de la tabla global ivoa.ObsCore sin requerir autenticación ni tokens para datos públicos.

2.2. API 2: ALeRCE Broker API (Centro de Modelamiento Matemático / MAS Chile)

Justificación Territorial en Chile: ALeRCE es una iniciativa tecnológica y científica concebida, desarrollada y operada enteramente en Chile por científicos e ingenieros del CMM (Facultad de Ciencias Físicas y Matemáticas, Universidad de Chile), MAS, UdeC y la Fundación Data Observatory, con financiamiento de ANID. Constituye una de las mayores plataformas de ciencia de datos del país.

Funcionamiento Técnico: ALeRCE procesa el torrente de alertas de telescopios de sondeo continuo (como el Zwicky Transient Facility - ZTF y próximamente el Observatorio Vera C. Rubin) y expone una API REST moderna y

abierta en https://api.alerce.online/ztf/v1/objects. La API devuelve objetos astronómicos en formato JSON, soportando paginación por page y page_size, ordenamiento por lastmjd y filtrado por clasificador de Machine Learning (lc_classifier).

Atributo Técnico	API 1: ESO Science Archive	API 2: ALeRCE Broker Chile
Tipo de Servicio	IVOA TAP (ADQL síncrono)	REST API (JSON estructurado)
Endpoint Base	https://archive.eso.org/tap_obs/sync	https://api.alerce.online/ztf/v1/objects
Autenticación	Pública (No requiere credencial)	Pública (No requiere credencial)
Paginación / Límite	Cláusula ADQL: TOP N	Parámetros: page, page_size (máx 100)
Entidad Principal	Observación científica (obs_id)	Objeto de alerta transitoria (oid)
Campos Temporales	t_min (Modified Julian Date)	lastmjd, firstmjd (Modified Julian Date)
Campos Espaciales	s_ra, s_dec (coordenadas ecuatoriales)	meanra, meandec (coordenadas ecuatoriales)

3. Problema de Gestión Operativa y Campos de Cruce

Problema de Gestión a Medir: El costo operativo por hora de un telescopio de 8 metros en Cerro Paranal asciende a decenas de miles de dólares, y la demanda de tiempo de observación por parte de astrónomos supera en más de 400% la disponibilidad nocturna. Simultáneamente, el broker ALeRCE genera cientos de alertas diarias de objetos que cambian de brillo súbitamente en el cielo visible desde Chile. **La gestión del sector astronómico requiere medir si el tiempo de exposición y la instrumentación disponible en Chile están asignándose de manera armónica respecto a la densidad espacial de alertas transitorias detectadas.**

Para lograr este análisis comparativo, las dos fuentes de datos son integradas dimensionalmente a través de dos campos de cruce rigurosamente diseñados:

3.1. Campo de Cruce 1: Dimensión Temporal Unificada (fecha_id / DATE)

Ambas APIs reportan el instante temporal en el sistema estándar de la astronomía: **Modified Julian Date (MJD)**. El MJD es una escala continua de días fraccionales donde el MJD 0.0 corresponde exactamente al 17 de noviembre de 1858 a las 00:00:00 UTC. Durante la etapa de transformación ETL en Python, se implementa la función de conversión formal:

> ***Fórmula de Conversión Temporal:***
> *Fecha_Calendario = Datetime(1858, 11, 17) + Timedelta(dias=MJD_val)*
> *Ejemplo: MJD 61341.547 -> 2026-10-28 (Día exacto de observación nocturna en Chile).*

Esta transformación genera una clave primaria temporal fecha_id (DATE) que vincula a la dimensión dw.dim_tiempo, permitiendo consolidar tanto las observaciones de ESO como las alertas de ALeRCE por fecha, mes, año, trimestre y día de la semana.

3.2. Campo de Cruce 2: Dimensión Espacial de Franjas Celestes (banda_declinacion_id)

En el espacio celeste, los telescopios y las alertas se orientan según el sistema de coordenadas ecuatoriales: **Ascensión Recta (RA)** de 0° a 360° y **Declinación (Dec)** de -90° a +90°. Dado que dos eventos nunca ocurrirán en coordenadas continuas idénticas al milisegundo de arco, el campo de cruce espacial requiere un proceso de discretización o 'binning'.

Se diseñó una discretización en **franjas regulares de 10 grados de declinación**:

> ***Fórmula de Discretización Espacial:***
> *Limite_Inferior = floor(Declinacion / 10.0) * 10*
> *Banda_Declinacion = str(Limite_Inferior) + ' a ' + str(Limite_Inferior + 10)*
> *Ejemplo: Dec = -24.5° (Cielo visible en Paranal) -> Banda '-30 a -20' | Dec = +5.2° -> Banda '0 a 10'.*

Adicionalmente, la dimensión dw.dim_banda_cielo cataloga cada franja según su **Hemisferio Celeste** ('Austral' para Dec < 0° y 'Boreal' para Dec ≥ 0°). Esto permite cruzar directamente el tiempo de exposición de los telescopios chilenos en cada franja del cielo frente al número de alertas detectadas en esa misma banda.

4. Paso a Paso de la Solución: Extracción, Transformación y Carga (ETL)

4.1. Extracción en Python (Módulos extract_eso y extract_alerce)

La extracción se programó en Python mediante la librería requests, asegurando las siguientes restricciones de robustez exigidas por la rúbrica:

- **Validación Previa de API:** Cada proceso ejecuta una tarea de prueba de conectividad (validar_api_eso y validar_api_alerce) con timeout corto antes de lanzar extracciones intensivas.
- **Manejo de Errores HTTP y Timeouts:** Se controlan excepciones de red (ConnectTimeout, ReadTimeout, HTTPError) con reintentos automáticos.
- **Paginación y Límites:** Para ALeRCE se implementó paginación ordenada por lastmjd DESC con páginas de 100 registros y control de pausas para no saturar el servicio. Para ESO se empleó la cláusula ADQL SELECT TOP {limite} acotada por ventanas de MJD.
- **Inmutabilidad en Capa RAW:** La respuesta JSON completa se almacena intacta en formato JSONB en las tablas raw.eso_observations_raw y raw.alerce_objects_raw junto con el run_id y timestamp de extracción.

4.2. Transformaciones Documentadas en Python (Módulo transform)

Se documentan formalmente las **6 transformaciones de datos** realizadas con pandas y numpy:

#	Transformación	Descripción Técnica y Regla de Negocio
1	**Conversión de Tipos y Fechas**	Conversión de t_min y lastmjd (MJD numérico) a fecha_observacion tipo DATE estándar (YYYY-MM-DD) mediante suma de días base 1858-11-17.
2	**Renombrado y Estandarización**	Mapeo homogéneo: t_exptime -> tiempo_exposicion_seg; access_estsize -> tamano_estimado_kb; class -> class_name; probability -> probabilidad_clase; ndet -> num_detecciones.
3	**Tratamiento de Nulos y Atípicos**	Filtrado de registros con coordenadas físicas corruptas (dec fuera de [-90, 90] o ra fuera de [0, 360]) y tiempos de exposición ≤ 0. Imputación de tamaños nulos con 0 y cálculo del % de nulos para la tabla de auditoría.
4	**Normalización de Textos**	Eliminación de espacios en blanco (trim) y conversión a mayúsculas de instrument_name (ej. 'uves' -> 'UVES', 'harps' -> 'HARPS') y dataproduct_type ('IMAGE', 'SPECTRUM', 'CUBE').
5	**Creación de Campos Calculados**	Cálculo de volumen en megabytes: tamano_estimado_mb = tamano_estimado_kb / 1024.0. Cálculo de la dimensión espacial: banda_declinacion (tramos de 10°) y hemisferio ('Austral' vs 'Boreal').
6	**Desduplicación e Idempotencia**	Aplicación de df.drop_duplicates(subset=['obs_id']) y df.drop_duplicates(subset=['oid']) para eliminar duplicidad en memoria antes de la persistencia relacional.

4.3. Carga y Modelo de Datos Dimensional en PostgreSQL

La base de datos dw_astronomia se diseñó organizando la información en **4 esquemas lógicos** que garantizan la separación de responsabilidades y el cumplimiento de las mejores prácticas de Data Warehousing:

- **raw:** Almacenamiento crudo en tablas eso_observations_raw y alerce_objects_raw con payloads JSONB inmutables, permitiendo la trazabilidad del dato original.
- **staging:** Tablas stg_eso_observations y stg_alerce_objects con datos limpios, fuertemente tipados, desduplicados y con columnas enriquecidas.
- **dw:** Modelo Dimensional en Estrella (Star Schema) integrado por tres dimensiones compartidas (dim_tiempo, dim_banda_cielo, dim_instrumento) y dos tablas de hechos (fact_observaciones_eso y fact_alertas_alerce).
- **mart:** Vistas materializadas y tablas de KPIs agregados con métricas de productividad, calidad, almacenamiento y cobertura espacial.
- **public.etl_audit:** Tabla transversal de auditoría que registra cada corrida con filas leídas, filas cargadas, porcentaje de nulos, duración y estado.

Garantía de Idempotencia: Cada operación de carga utiliza cláusulas ON CONFLICT DO UPDATE o DO NOTHING. Por ejemplo, en dw.fact_observaciones_eso se aplica ON CONFLICT (obs_id) DO UPDATE SET tiempo_exposicion_seg = EXCLUDED.tiempo_exposicion_seg, tamano_estimado_mb = EXCLUDED.tamano_estimado_mb. De este modo, volver a ejecutar un DAG o reprocesar un rango temporal jamás duplica filas ni corrompe los indicadores agregados.

5. Orquestación y Estrategia de Ejecución en Apache Airflow

La solución cuenta con **3 DAGs completamente desacoplados** en Apache Airflow, asegurando que la falla de una fuente externa no bloquee ni comprometa el resto del flujo de datos:

Nombre del DAG	Schedule	Responsabilidad y Flujo de Tareas	Dependencia / Disparador
dag_1_etl_eso_archive	@daily (0 2 * * *)	Validar API ESO TAP → Extraer JSON a raw → Transformar y limpiar → Cargar en DW → Registrar etl_audit → Disparar DAG 3.	Independiente. Trigger al terminar.
dag_2_etl_alerce_chile	@daily (0 2 * * *)	Validar API ALeRCE → Extraer páginas JSON a raw → Transformar y validar ML → Cargar en DW → Registrar etl_audit → Disparar DAG 3.	Independiente. Trigger al terminar.
dag_3_kpi_mart_astronomico	Disparado o (0 3 * * *)	Ejecutar agregaciones SQL sobre dw → Actualizar las 5 tablas del esquema mart → Registrar etl_audit.	Disparado por DAG 1 y DAG 2 (TriggerDagRunOperator).

5.1. Manejo de Credenciales y Variables de Airflow

Dando estricto cumplimiento a la restricción 4 de la pauta (*'No se deben incluir contraseñas ni claves de API en el código'*), los DAGs se configuran dinámicamente mediante componentes nativos de Airflow:

- **Airflow Connection (postgres_dw):** Configurada en la UI de Airflow (Admin → Connections) apuntando al host, puerto y credenciales de la base de datos PostgreSQL, consumida mediante PostgresHook.
- **Airflow Variables:** Variables eso_api_url y alerce_api_url definidas en Admin → Variables, permitiendo modificar los endpoints sin tocar el código fuente.

5.2. Tolerancia a Fallas y Callback de Auditoría

Se configuró en default_args de cada DAG una estrategia de reintentos y timeouts orientada a la demostración en vivo:

```
default_args = {
    'retries': 2,
    'retry_delay': timedelta(seconds=15), # 15s para demostración ágil
    'execution_timeout': timedelta(minutes=5),
    'on_failure_callback': registrar_falla_audit
}
```

Cuando una tarea falla tras agotar sus reintentos, el callback registrar_falla_audit se activa de forma automática, insertando en public.etl_audit el dag_id, run_id, duración, estado 'FAILED' y el mensaje de excepción detallado.

5.3. Demostración de Falla Controlada en Vivo (Presentación de 8 minutos)

Para la exposición grupal ante la comisión docente, el grupo preparó el siguiente protocolo de prueba en vivo:

1. **Provocar Falla:** En la UI de Airflow (Admin → Variables), cambiar temporalmente eso_api_url a una URL rota: https://archive.eso.org/tap_obs/url_rota_demo.
2. **Ejecutar DAGs:** Activar manualmente dag_1_etl_eso_archive y dag_2_etl_alerce_chile.
3. **Evidencia Visual:** En la pantalla de Airflow, la tarea de validación de ESO pasa a estado *up_for_retry* (amarillo), reintenta 2 veces cada 15 segundos y finaliza en *failed* (rojo).
4. **Aislamiento y Auditoría:** Mostrar en PostgreSQL la consulta SELECT * FROM public.etl_audit WHERE estado = 'FAILED';, evidenciando el registro de la caída. Paralelamente, dag_2_etl_alerce_chile y dag_3_kpi_mart_astronomico terminan exitosamente en verde (*success*).
5. **Recuperación Idempotente:** Restaurar la URL correcta en la Variable de Airflow, aplicar 'Clear Task' a la tarea fallida y demostrar cómo el flujo se reanuda e inserta los datos de forma idempotente sin duplicados.

6. Definición, Cálculo y Resultados de los 5 Indicadores de Gestión

Se diseñaron 5 indicadores de gestión calculados mediante consultas SQL agregadas en el esquema mart, respondiendo a preguntas operativas y estratégicas del sector:

#	Indicador de Gestión	Objetivo y Decisión	Fórmula Matemática	Fuente	Meta / Umbral
1	**Horas Efectivas de Exposición Diaria**	Medir el aprovechamiento productivo del tiempo nocturno en telescopios de ESO en Chile.	Σ(tiempo_exposicion_seg) / 3600.0	ESO (fact_obs)	≥ 8.0 horas conjuntas por noche.
2	**Volumen Diario de Datos (GB/día)**	Dimensionar la carga de transferencia de red y almacenamiento digital de productos científicos.	Σ(tamano_estimado_mb) / 1024.0	ESO (fact_obs)	Alerta operativa si supera 500 GB/día.
3	**Tasa de Calibración Avanzada Ciencia**	Evaluar la calidad y nivel de procesamiento de los datos científicos entregados (calib_level ≥ 2).	(COUNT(calib ≥ 2) / COUNT(*)) * 100	ESO (fact_obs)	≥ 75% en nivel ciencia validado.
4	**Índice de Alta Confianza en Alertas**	Medir la certidumbre del clasificador de Machine Learning chileno (lc_classifier) en eventos transitorios.	(COUNT(prob ≥ 0.70) / COUNT(*)) * 100	ALeRCE (fact_alertas)	≥ 60% de alertas con prob ≥ 0.70.
5	**Cobertura de Seguimiento por Banda (Cruce)**	Identificar qué franjas de declinación con alertas están siendo cubiertas por telescopios en Chile.	Minutos ESO en Banda / N° Alertas ALeRCE en Banda	Cruce ESO + ALeRCE	≥ 5.0 min/alerta en Hemisferio Austral.

6.1. Evidencia de Resultados Empíricos en PostgreSQL

A continuación se presentan muestras reales extraídas directamente de las tablas del esquema mart tras la ejecución del pipeline con datos de producción:

Muestra Real: Indicador 5 — Cobertura de Seguimiento (Cruce ESO vs ALeRCE)

Fecha	Banda Dec	Hemisferio	Min ESO	Alertas	Ratio Min/Alerta	Diagnóstico Operacional
2026-10-28	-80 a -70	Austral	10.37 min	0	N/A	**COBERTURA MODERADA / BOREAL**
2026-10-28	-60 a -50	Austral	3.03 min	0	N/A	**COBERTURA MODERADA / BOREAL**
2026-10-28	20 a 30	Boreal	0.00 min	49	0.00 min/al	**COBERTURA MODERADA / BOREAL**
2026-10-28	0 a 10	Boreal	0.00 min	108	0.00 min/al	**COBERTURA MODERADA / BOREAL**

7. Capítulo Especial: Estrategia de Datos y Gobernanza

Una solución de Inteligencia de Negocios en el ámbito astronómico demanda una estrategia integral que regule la toma de decisiones, la calidad, el linaje, la gestión de riesgos y la escalabilidad ante nuevos observatorios en Chile.

7.1. Usuarios Clave y Decisiones de Negocio que Apoyan los Indicadores

Los indicadores calculados en la capa MART satisfacen las necesidades de tres perfiles de usuarios estratégicos en el ecosistema astronómico chileno:

- **Directores de Operaciones de Telescopios (ESO / Paranal / La Silla):** Utilizan los KPIs 1 y 5 para evaluar si la programación nocturna y la asignación de tiempo en telescopios como el VLT están respondiendo ágilmente a eventos transitorios críticos. Permite tomar decisiones de interrupción de programas estándar (*Target of Opportunity - ToO*) para apuntar telescopios hacia alertas de alta prioridad.
- **Equipos de Ciencia de Datos e Inteligencia Artificial (ALeRCE / CMM / MAS):** Emplean el KPI 4 para monitorear el desempeño del clasificador lc_classifier. Una caída en la tasa de alta confianza activa protocolos de reentrenamiento de modelos con nuevas curvas de luz y ajuste de hiperparámetros.
- **Ingenieros de Infraestructura TI y Almacenamiento:** Supervisan el KPI 2 (GB/día) para dimensionar las cuotas de almacenamiento en discos locales en Paranal, prever saturaciones en el enlace de fibra óptica Paranal-Antofagasta-Santiago y gestionar el archivado hacia la nube científica.

7.2. Gobierno y Calidad de Datos: Nulos, Duplicados y Consistencia

La confiabilidad analítica del Data Warehouse descansa sobre rigurosos controles de calidad automatizados en la etapa de transformación:

- **Monitoreo y Cuantificación de Nulos:** Las APIs abiertas presentan disparidad estructural. En ESO, atributos mandatorios como obs_id, instrument_name y coordenadas físicas presentan 0% de nulos, mientras que en ALeRCE campos contextuales opcionales (tales como g_r_max o sigmara) presentan una tasa de nulos promedio de 17.39%. Esta cifra es calculada dinámicamente y registrada en public.etl_audit para cada corrida.
- **Eliminación de Duplicados:** Tanto en memoria (drop_duplicates) como en base de datos mediante índices únicos sobre obs_id y oid, evitando la sobrestimación de horas de exposición o conteo de alertas.
- **Consistencia Semántica entre Fuentes:** Se armonizaron las coordenadas ecuatoriales continuas mediante la discretización de 10° en dw.dim_banda_cielo y la unificación de calendarios en dw.dim_tiempo, garantizando que ambas fuentes conversen en un plano dimensional común.

7.3. Origen del Dato y Linaje (Data Lineage)

El linaje del dato describe el ciclo de vida completo de cada registro desde su emisión externa hasta su consulta en los reportes de gestión:

Cadena de Linaje de Datos:

1. ***Origen:*** *archive.eso.org (ADQL) & api.alerce.online (REST JSON).*
2. ***Capa RAW:*** *Inserción inmutable de payloads completos en raw.*_raw (JSONB).*
3. ***Capa STAGING:*** *Limpieza, tipado, conversión MJD a DATE y filtrado de anomalías.*
4. ***Capa DW:*** *Generación de surrogate keys y enlace relacional Hechos-Dimensiones (Star Schema).*
5. ***Capa MART:*** *Consultas de agregación SQL para los 5 KPIs analíticos de negocio.*

7.4. Frecuencia de Actualización y Relación con el Schedule de los DAGs

La frecuencia de ejecución de los DAGs fue seleccionada considerando la naturaleza física del fenómeno observado:

- **Schedule Diario (02:00 UTC / 23:00 hora de Chile):** Los telescopios operan durante la noche. Al amanecer en Chile (10:00 UTC), las observaciones y alertas de la noche previa están consolidadas en los servidores de ESO y ALeRCE. Ejecutar los DAGs en dicho horario asegura que los informes estén disponibles al iniciar la jornada de trabajo de los directores de operaciones.
- **Backfill y Recarga Histórica (catchup=True):** La arquitectura soporta re-ejecutar rangos de fechas pasados mediante parámetros mjd_inicio y mjd_fin sin duplicar registros gracias a la idempotencia.

7.5. Gestión de Riesgos y Mitigación Operativa

Se identificaron y mitigaron proactivamente cuatro riesgos inherentes al consumo de APIs públicas:

Riesgo Operativo	Impacto Potencial	Estrategia de Mitigación Implementada
Caída o Indisponibilidad de API Externa	Bloqueo del pipeline y retraso en el cálculo de métricas de negocio.	Tarea previa de validación HTTP. Desacoplamiento total: la caída de ESO no detiene a ALeRCE. DAG 3 calcula sobre datos existentes sin colapsar.
Límites de Consulta y Rate Limiting	Bloqueo temporal de la IP por exceso de peticiones síncronas.	Uso de TOP {limite} en ADQL, paginación controlada con pausas de 150ms en ALeRCE y persistencia cruda en RAW para no re-consultar la API.
Cambios de Esquema en JSON	Falla de deserialización o pérdida de columnas en staging.	Almacenamiento de payload completo en JSONB inmutable y uso de valores por defecto defensivos (.fillna(), errors='coerce').
Timeouts de Red en Servidores Remotos	Interrupción abrupta de la descarga de datos.	Timeouts explícitos en requests.get, retries=2 con espera de 15s y registro automático en public.etl_audit vía callbacks.

7.6. Licencias, Políticas de Open Science y Datos Sensibles

Ambas fuentes seleccionadas se rigen por políticas internacionales de **Ciencia Abierta (Open Science)**. El Observatorio Europeo Austral libera los metadatos y datos de observaciones públicas inmediatamente después del periodo estándar de embargo propietario (habitualmente 1 año asignado al investigador principal), bajo directrices de acceso abierto para la comunidad científica. Por su parte, el broker ALeRCE publica las alertas procesadas de manera 100% pública e instantánea bajo licencias permisivas de investigación.

Privacidad y Normativa Chilena: Ninguna de las fuentes involucra datos de carácter personal, números de identificación (RUT), datos biométricos ni información comercial confidencial sujeta a la Ley N° 19.628 sobre Protección de la Vida Privada. La solución es 100% inocua y éticamente intachable para su explotación académica y pública.

7.7. Escalabilidad Futura hacia el Observatorio Vera C. Rubin (LSST)

El panorama de la astronomía en Chile experimentará una revolución en 2025-2026 con el inicio de operaciones del **Observatorio Vera C. Rubin en Cerro Pachón (Región de Coquimbo)**. Su telescopio de sondeo sinóptico (LSST) generará aproximadamente **10 millones de alertas astronómicas transitorias por noche** (alrededor de 20 Terabytes de datos brutos cada día). ALeRCE es uno de los pocos brokers seleccionados oficialmente a nivel mundial para procesar dicho torrente.

Nuestra arquitectura fue diseñada con visión de escalabilidad empresarial para absorber dicho volumen masivo:

- **Particionamiento de Tablas en PostgreSQL:** Migración de dw.fact_alertas_alerce hacia particionamiento nativo por rango temporal mensual (PARTITION BY RANGE (fecha_id)) y sub-particionado por banda_sk, optimizando las consultas de agregación sin degradación por volumen.
- **Transición a Procesamiento Distribuido:** Dado que la lógica de transformación en src/transform.py está modularizada y desacoplada de la base de datos, las funciones pueden ser trasladadas a **Apache Spark / PySpark** y la ingesta hacia **Apache Kafka** manteniendo inalteradas las definiciones dimensionales de la capa MART.

8. Evidencia de Carga y Tabla de Auditoría (public.etl_audit)

A continuación se presenta la transcripción íntegra de los registros capturados en la tabla public.etl_audit durante las fases de prueba, ejecución normal y demostración de falla controlada:

ID	DAG ID	Fuente	Leídas	Cargadas	% Nulos	Segs	Estado	Detalle Error / Excepción
1	1_etl_eso_archive	ESO_Science_	0	0	0.00%	4.03	FAILED	INSERT has more target columns than...
2	2_etl_alerce_chile	ALeRCE_Broke	0	0	0.00%	16.01	FAILED	HTTPSConnectionPool (host='api.alerc...
3	3_kpi_mart_astronomico	dw_star_sche	0	0	0.00%	0.05	SUCCESS	Ninguno (OK)
4	1_etl_eso_archive	ESO_Science_	1000	275	0.00%	4.13	SUCCESS	Ninguno (OK)
5	2_etl_alerce_chile	ALeRCE_Broke	500	371	17.39%	40.18	SUCCESS	Ninguno (OK)
6	3_kpi_mart_astronomico	dw_star_sche	164	164	0.00%	0.05	SUCCESS	Ninguno (OK)
7	3_kpi_mart_astronomico	dw_star_sche	198	198	0.00%	0.06	SUCCESS	Ninguno (OK)
8	1_etl_eso_archive	ESO_Science_	0	0	0.00%	4.12	FAILED	HTTPError 404: Endpoint not found e...
9	2_etl_alerce_chile	ALeRCE_Broke	200	149	17.39%	26.75	SUCCESS	Ninguno (OK)
10	3_kpi_mart_astronomico	dw_star_sche	198	198	0.00%	0.06	SUCCESS	Ninguno (OK)
11	1_etl_eso_archive	ESO_Science_	100	52	0.00%	3.25	SUCCESS	Ninguno (OK)

8.1. Métricas Consolidadas de Ejecución

- **Total de Registros Cargados en Hechos ESO:** Más de 300 observaciones científicas de ALMA, HARPS, UVES y FEROS con tiempos de exposición validados.
- **Total de Registros Cargados en Hechos ALeRCE:** Más de 500 alertas clasificadas con probabilidades y recuento de detecciones.
- **Porcentaje de Nulos Detectado:** 0.00% en ESO (metadatos IVOA estrictos); 17.39% en ALeRCE (debido a atributos optativos de fotometría).
- **Tiempos Medios de Ejecución:** DAG 1 (ESO): ~4.1 segundos | DAG 2 (ALeRCE): ~26 a 40 segundos (por paginación HTTP controlada) | DAG 3 (Mart): ~0.06 segundos.

9. Análisis del Proceso, Problemas Detectados y Soluciones

Dando respuesta a las preguntas mínimas exigidas en la sección de Análisis del Proceso:

1. ¿Qué hallazgos surgieron al cargar los datos?
Al cruzar las observaciones de telescopios de ESO frente a las alertas de ALeRCE (KPI 5), se evidenció que ciertas franjas australes del cielo (especialmente declinaciones entre -30° y 0°) concentran un volumen relevante de alertas de objetos transitorios nuevos clasificados por ALeRCE, pero presentan 0 minutos de exposición en telescopios

mayores durante la misma fecha. Esto constata empíricamente una **oportunidad de mejora operacional: existe una brecha de seguimiento observacional que justificaría activar convenios de asignación rápida de telescopios chilenos hacia alertas de ALeRCE**.

2. ¿Qué problemas detectaron y cómo los resolvieron?
• *Disparidad en Sistemas Temporales:* Ambas APIs utilizaban Modified Julian Date en vez de fechas humanas. Se solucionó mediante la implementación matemática del epoch 1858-11-17 en Python.
• *Timeouts Ocasionales en ALeRCE:* La API de ALeRCE presentó demoras puntuales bajo alta concurrencia. Se resolvió ampliando el timeout a 35 segundos, agregando reintentos con backoff y separando las descargas en páginas de 100 elementos.
• *Duplicidad de Identificadores en Productos Reducidos:* Algunas observaciones de ALMA contenían múltiples archivos para un mismo obs_id. Se depuraron con drop_duplicates en Python y ON CONFLICT DO UPDATE en PostgreSQL.

3. ¿Qué fallas ocurrieron en las APIs o en Airflow y cómo respondió el diseño de los DAGs?
Durante las pruebas controladas (Audit ID 8), se simuló la caída de la API de ESO mediante una URL inválida. El DAG 1 ejecutó 2 reintentos cada 15 segundos y gatilló automáticamente la función registrar_falla_audit, registrando el error en public.etl_audit. **El aislamiento de los DAGs demostró su efectividad total: DAG 2 continuó operando sin perturbación y DAG 3 recalculó los indicadores sobre los datos disponibles sin bloquearse.**

10. Conclusiones y Referencias

El proyecto demostró con éxito que es factible articular una arquitectura analítica robusta, tolerante a fallas y reproducible utilizando fuentes de datos abiertas chilenas en el sector astronómico. El uso combinado de Apache Airflow, Python y PostgreSQL bajo un modelo dimensional en estrella permitió convertir datos heterogéneos en 5 indicadores de alto impacto para la gestión científica y operativa de Chile.

Referencias Bibliográficas:

- European Southern Observatory (ESO). (2026). *ESO Science Archive Facility & IVOA Table Access Protocol (TAP) ObsCore Documentation*. Garching, Germany / Cerro Paranal, Chile.
- Förster, F., Cabrera-Vives, G., Castillo-Navarrete, E., et al. (2021). *The Automatic Learning for the Rapid Classification of Events (ALeRCE) Alert Broker*. The Astronomical Journal, 161(5), 242.
- Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling* (3rd ed.). Wiley.
- Apache Software Foundation. (2026). *Apache Airflow Documentation: Architecture, DAGs, and Resilient Task Execution*.